

#خوانش_گروهی_با_فیلاگر

مطالعه کتاب و مقالات هوش مصنوعی به صورت گروهی در فیلاگر



رفیه فرجی
کارشناسی ارشد فیزیک اتمی




فیلاگر اجامه هوش مصنوعی ایران



فصل دوم

آشنایی با جبر خطی

- معرفی ماتریس‌های خاص
- تجزیه ماتریس‌ها
- پیدا کردن معکوس ماتریس‌ها
- عملگر Trace
- دترمینان
- روش PCA



ماتریس‌ها و بردارهای خاص

$$A = \begin{bmatrix} -1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

$D_{i,j} = 0$ for all unequal i, j

ماتریس قطری:

$$\mathbf{v} = \begin{bmatrix} -1 \\ 2 \\ 3 \end{bmatrix} \longrightarrow \text{diag}(\mathbf{v}) = \begin{bmatrix} -1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

نمایش

$$\text{diag}(\mathbf{v})\mathbf{x} = \mathbf{v} \cdot \mathbf{x}$$

کاربردها

$$I_n = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix}.$$

ماتریس همانی

$$\begin{bmatrix} -3 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 7 \end{bmatrix}^{-1} = \begin{bmatrix} 1/3 & 0 & 0 \\ 0 & 1/4 & 0 \\ 0 & 0 & 1/7 \end{bmatrix}$$

ماتریس‌ها و بردار‌های خاص

ماتریس متقارن:

$$A^T = A$$

$$\begin{bmatrix} 1 & 1 & -1 \\ 1 & 2 & 0 \\ -1 & 0 & 5 \end{bmatrix}$$

اگر بخواهیم فاصله نقاط را بصورت ماتریس بیان کنیم
چون فاصله دو نقطه مستقل از این است که ما فاصله را از
نقطه اول تا دوم حساب کنیم یا بر عکس حاصل ماتریسی
متقارن می‌باشد

مثال

بردار واحد:

$$\|x\|_2 = 1.$$

بردارهای متعامد:

$$x^\top y = 0.$$

ماتریس‌ها و بردار‌های خاص

$$\mathbf{A}^\top \mathbf{A} = \mathbf{A} \mathbf{A}^\top = \mathbf{I}.$$



$$\mathbf{A}^{-1} = \mathbf{A}^\top.$$

ماتریسی که سطر‌های آن بر هم عمود باشند یا همچنین ستون‌های آن بر هم عمود باشند را ماتریس متعامد گوییم

ویژگی حائز اهمیت این ماتریس در آن است که معکوس آن برآختی قابل محاسبه است

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} \frac{1}{3} & \frac{2}{3} & -\frac{2}{3} \\ -\frac{2}{3} & \frac{2}{3} & \frac{1}{3} \\ \frac{2}{3} & \frac{1}{3} & \frac{2}{3} \end{pmatrix} \begin{pmatrix} \frac{1}{3} & -\frac{2}{3} & \frac{2}{3} \\ \frac{2}{3} & \frac{2}{3} & \frac{1}{3} \\ -\frac{2}{3} & \frac{1}{3} & \frac{2}{3} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \mathbf{I}$$

\mathbf{A} is orthogonal.

تجزیه ماتریس‌های روش Eigendecomposition

در این روش به دنبال خصوصیاتی از ماتریس‌ها هستیم که universal باشد

$$A\mathbf{v} = \lambda\mathbf{v}.$$

روش decomposition اطلاعاتی از ماتریس‌ها را بدست می‌دهد که با مشاهده ماتریس قابل تفسیر نیست

یکی از روش‌های Matrix decomposition استفاده از روش Eigen decomposition می‌باشد


$$V = [v^{(1)}, \dots, v^{(n)}]$$

$$\lambda = [\lambda_1, \dots, \lambda_n]$$



$$A = V \text{diag}(\lambda) V^{-1}.$$

تجزیه ماتریس‌های روش Eigendecomposition



در شکل رو برو تاثیر بردارهای ویژه و مقادیر ویژه را مشاهده می‌کنید.

در شکل سمت چپ قبل از اعمال ضرب ماتریس A می‌باشد

در شکل سمت راست بعد از ضرب در ماتریس A مشاهده می‌شود که در همان راستاهای بردار ویژه‌ها باقی مانده منتها با مقادیر ویژه

تجزیه ماتریس‌هابه روش Eigendecomposition

لزوماً همهٔ ماتریس‌ها دارای بردار ویژه و مقدار ویژه نیستند

ها ماتریس‌های متعامد هستند \mathbf{Q}

$$\mathbf{A} = \mathbf{Q}\Lambda\mathbf{Q}^\top$$

تجزیه ماتریس
متقارن

هر ماتریس متقارنی حتماً دارای مقادیر ویژه است اما لزوماً می‌تواند تجزیه واحدی نباشد

هرگاه برای دو بردار ویژه مقدار ویژه یکسان داشته باشیم می‌توان از span ها برای ساختن ماتریس متعامد استفاده کرد

تجزیه ماتریس‌های روش Eigendecomposition

$$f(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$$

هرگاهتابع مقابله باخواهیم بهینه کنیم در شرایطی که ماتریس متقارن باشد و \mathbf{x} بردار ویژه آن باشد می‌توان مقدار بیشینه یا کمینه آن را از روی مقادیر ویژه محاسبه کرد

: به ماتریس‌هایی گفته می‌شود که مقادیر ویژه‌ها مثبت است positive definite

: به ماتریس‌هایی گفته می‌شود که مقادیر ویژه‌ها مثبت و یا صفر است positive semidefinite


: به ماتریس‌هایی گفته می‌شود که مقادیر ویژه‌ها منفی است negative definite

: به ماتریس‌هایی گفته می‌شود که مقادیر ویژه‌ها منفی و یا صفر است negative semidefinite

Singular Value Decomposition

روش singular value decomposition راه دیگری برای فاکتوربندی ماتریس‌ها ارائه می‌دهد در این روش همانند قبل ویژگی‌هایی از ماتریس استخراج می‌شود که singular values و singular vectors نامیده می‌شوند

بطور کلی این روش برای همه ماتریس‌ها جواب دارد



ماتریس متعامدی می‌باشد
که ستون‌های آن
left-singular
vectors نامیده می‌شوند

45

ماتریس قطری بوده و عناصر آن singular values نامیده می‌شوند

ماتریس متعامدی بوده که ستون‌های آن right-singular vectors نامیده می‌شوند

$U:m \times m$

$$A = V \text{diag}(\lambda) V^{-1}.$$

از روش قبلی داشتیم

$D:m \times n$

$$A = UDV^\top.$$

A ماتریسی m در n می‌باشد

$V:n \times n$

در روش singular داریم

Singular Value Decomposition

بردار ویژه‌های $\mathbf{A}^\top \mathbf{A}$ ستون‌های \mathbf{V} را می‌سازند

بردار ویژه‌های $\mathbf{A}\mathbf{A}^\top$ ستون‌های \mathbf{U} را می‌سازند

ریشه دوم مقدار ویژه‌های $\mathbf{A}\mathbf{A}^\top$ عناصر قطری ماتریس \mathbf{D} را می‌سازند

محاسبه معکوس Moore-Penrose

$$\mathbf{A}^+ = \mathbf{V}\mathbf{D}^+\mathbf{U}^\top,$$

\mathbf{V} و \mathbf{U} ، \mathbf{D} ماتریس‌هایی مربوط به singular value decomposition هستند

ماتریس \mathbf{D} است که عناصر قطری آن معکوس شده‌اند \mathbf{D}^+

ترانهاده ماتریس \mathbf{U} می‌باشد \mathbf{U}^\top

عملگر Trace

این عملگر جمع عناصر روی قطر اصلی را محاسبه می‌کند

$$\text{Tr}(\mathbf{A}) = \sum_i A_{i,i}.$$

خیلی از محاسبات ریاضیاتی روی ماتریس‌ها با استفاده از این عملگر تسهیل می‌شوند

$$\|\mathbf{A}\|_F = \sqrt{\text{Tr}(\mathbf{A}\mathbf{A}^\top)}.$$

می‌توان نرم فربنیویس را بسادگی با استفاده از عملگر Trace محاسبه کرد

مثال

$$\text{Tr}(\mathbf{ABC}) = \text{Tr}(\mathbf{CAB}) = \text{Tr}(\mathbf{BCA})$$

خواص عملگر

$$\text{Tr}(\mathbf{A}) = \text{Tr}(\mathbf{A}^\top).$$

دترمینان

دترمینان ماتریس مربعی را با علامت $\det(A)$ نشان می‌دهیم.

دترمینان تابعی است که ماتریس را به فضای اسکالر نگاشت می‌کند.

دترمینان معادل با ضرب مقادیر ویژه ماتریس می‌باشد

دترمینان ماتریس معیاری است از اینکه بعد از ضرب ماتریسی فضافشرده یا منبسط می‌شود

Principal Components Analysis or PCA

فرض کنید m نقطه بصورت مقابل داشته باشیم و بخواهیم برای این نقاط lossy compression حساب کنیم

$$\mathbf{x}^{(i)} \in \mathbb{R}^n \longrightarrow \mathbf{c}^{(i)} \in \mathbb{R}^l.$$

فرض کنید تابعی وجود دارد مثل $f(x) = c$ که این کار را انجام می‌دهد در این صورت تابعی مانند $(f(x)) \approx g$ وجود دارد که مقادیر رو از فضای فشرده شده به فضای اصلی بر می‌گرداند

Principal Components Analysis or PCA

1

$$g(\mathbf{c}) = \mathbf{D}\mathbf{c}$$

2

$$\mathbf{c}^* = \arg \min_{\mathbf{c}} \|\mathbf{x} - g(\mathbf{c})\|_2.$$

3

$$\mathbf{c}^* = \arg \min_{\mathbf{c}} \|\mathbf{x} - g(\mathbf{c})\|_2^2.$$

$$= \arg \min_{\mathbf{c}} -2\mathbf{x}^\top \mathbf{D}\mathbf{c} + \mathbf{c}^\top \mathbf{c}$$

4

$$\nabla_{\mathbf{c}}(-2\mathbf{x}^\top \mathbf{D}\mathbf{c} + \mathbf{c}^\top \mathbf{c}) = \mathbf{0}$$

5

$$\mathbf{c} = \mathbf{D}^\top \mathbf{x}.$$

6

$$f(\mathbf{x}) = \mathbf{D}^\top \mathbf{x}.$$

7

$$r(\mathbf{x}) = g(f(\mathbf{x})) = \mathbf{D}\mathbf{D}^\top \mathbf{x}.$$

Principal Components Analysis or PCA

$$\mathbf{D}^* = \arg \min_{\mathbf{D}} \sqrt{\sum_{i,j} \left(x_j^{(i)} - r(\mathbf{x}^{(i)})_j \right)^2} \text{ subject to } \mathbf{D}^\top \mathbf{D} = \mathbf{I}_l$$

$$\mathbf{d}^* = \arg \min_{\mathbf{d}} \sum_i \|\mathbf{x}^{(i)} - \mathbf{d}\mathbf{d}^\top \mathbf{x}^{(i)}\|_2^2 \text{ subject to } \|\mathbf{d}\|_2 = 1.$$

$$\mathbf{d}^* = \arg \min_{\mathbf{d}} \sum_i \|\mathbf{x}^{(i)} - \mathbf{x}^{(i)\top} \mathbf{d}\mathbf{d}\|_2^2 \text{ subject to } \|\mathbf{d}\|_2 = 1.$$

Principal Components Analysis or PCA

$$\mathbf{d}^* = \arg \min_{\mathbf{d}} \|\mathbf{X} - \mathbf{X}\mathbf{d}\mathbf{d}^\top\|_F^2 \text{ subject to } \mathbf{d}^\top \mathbf{d} = 1.$$

$$= \arg \min_{\mathbf{d}} -\text{Tr}(\mathbf{X}^\top \mathbf{X} \mathbf{d} \mathbf{d}^\top) \text{ subject to } \mathbf{d}^\top \mathbf{d} = 1$$

$$= \arg \max_{\mathbf{d}} \text{Tr}(\mathbf{d}^\top \mathbf{X}^\top \mathbf{X} \mathbf{d}) \text{ subject to } \mathbf{d}^\top \mathbf{d} = 1$$

در فرمول نهایی پیداست که
مقدار نهایی می‌تواند وابسته
به مقادیر ویژه ماتریس
ورودی‌هاست

سپاس از همراهی شما



فیلاگر | جامعه هوش مصنوعی ایران